Gestión de Proyectos de Inteligencia Artificial

Actividad 5

Violeta Velázquez Villar

Link Google Colab:

https://colab.research.google.com/drive/14hoAAAkq3ljsp0ez3g_8WwiKTPkXajTz?usp=sharing

Link Hugging Face

https://github.com/vvelazquezv2025-gif/Actividad5

El objetivo de este proyecto fue desarrollar y comparar dos modelos de clasificación supervisada para distinguir entre observaciones malignas y benignas, utilizando el conjunto de datos Breast Cancer Wisconsin Diagnostic, disponible en la biblioteca scikit-learn.

Conjunto de datos: Breast Cancer Wisconsin Diagnostic
Algoritmos evaluados: Regresión logística y Random Forest
Entorno de desarrollo: Google Colab
Seguimiento de experimentos: MLflow

Se realizó la exploración y preparación de los datos, la verificación de su calidad y la separación en conjuntos de entrenamiento y prueba. Posteriormente, se entrenaron dos algoritmos: regresión logística y Random Forest. Para seleccionar sus hiperparámetros se utilizó GridSearchCV con validación cruzada estratificada de cinco particiones y la métrica F1 como criterio de optimización.

Los resultados muestran que la regresión logística obtuvo el mejor desempeño general

	Modelo	Accuracy (%)	Precision (%)	Recall (%)	F1 (%)	AUC-ROC (%)	F1 CV (%)
0	Random_Forest	97.37	100.0	92.86	96.3	99.29	95.19
1	Regresion_Logistica	99.12	100.0	97.62	98.8	99.77	96.71

Para comparar los modelos se consideraron los siguientes criterios:

- **Exactitud (Accuracy):** proporción de predicciones correctas respecto al total de observaciones.
- **Precisión (Precision):** proporción de predicciones positivas que corresponden a casos positivos reales.
- **Sensibilidad (Recall):** proporción de casos positivos reales identificados correctamente.
- **F1:** media armónica entre precisión y sensibilidad.

- **AUC-ROC:** capacidad del modelo para distinguir entre las dos clases a través de distintos umbrales.
- **F1 de validación cruzada:** mejor puntuación media de F1 obtenida durante la búsqueda de hiperparámetros.
- **Reproducibilidad:** posibilidad de repetir el entrenamiento y consultar parámetros, métricas y artefactos registrados mediante MLflow.

Descripción y preparación de los datos

El conjunto contiene 569 registros y 31 columnas: 30 variables predictoras numéricas y una variable objetivo.

Verificación de calidad

Durante la revisión de los datos se obtuvo el siguiente resultado:

Validación	Resultado
Registros	569
Columnas	31
Valores faltantes	0
Filas duplicadas	0
Valores infinitos	0

Las verificaciones realizadas no identificaron valores faltantes ni duplicados. Por esta razón, se conservó la información del conjunto original al crear la versión limpia.

División de los datos

Los datos se dividieron en un 80% para entrenamiento y un 20% para prueba, utilizando random_state=42 y estratificación para conservar la proporción de clases.

Conjunto	Registros
Entrenamiento	455
Prueba	114
Total	569

Para la validación cruzada se utilizó StratifiedKFold con cinco particiones.

Los archivos de datos se organizaron en las carpetas datos/datos_ini/ y datos/datos_limp

Algoritmos y ajuste de hiperparámetros

Regresión logística

Se implementó un pipeline compuesto por StandardScaler y LogisticRegression, con max_iter=5000 y semilla aleatoria 42.

La búsqueda de hiperparámetros evaluó:

- C: 0.1, 1 y 10.
- class_weight: None y balanced.

Random Forest

Se utilizó RandomForestClassifier, con random_state=42 y n_jobs=1.

Este algoritmo combina múltiples árboles de decisión y permite representar relaciones no lineales entre las variables.

Los siguientes resultados proceden de las corridas finalizadas registradas en MLflow.

Métrica	Regresión logística	Random Forest
Accuracy	99.12%	97.37%
Precision	100.00%	100.00%
Recall	97.62%	92.86%
F1	98.80%	96.30%
AUC-ROC	99.77%	99.29%
F1 de validación cruzada	96.71%	95.19%

Análisis comparativo

Regresión logística

Ventajas:

- Obtuvo las mejores métricas generales en esta evaluación.
- Presenta una estructura relativamente sencilla de interpretar.
- Alcanzó mayor sensibilidad para identificar casos malignos en el conjunto de prueba.

Limitaciones:

- Puede tener dificultades para representar relaciones complejas cuando las fronteras entre clases no son aproximadamente lineales.
- Su rendimiento puede cambiar al aplicarse a datos de otra población o distribución.

Random Forest

Ventajas:

- Puede modelar relaciones no lineales.
- Combina varios árboles de decisión.

- Requiere menos preparación de escalado de variables para su funcionamiento habitual.

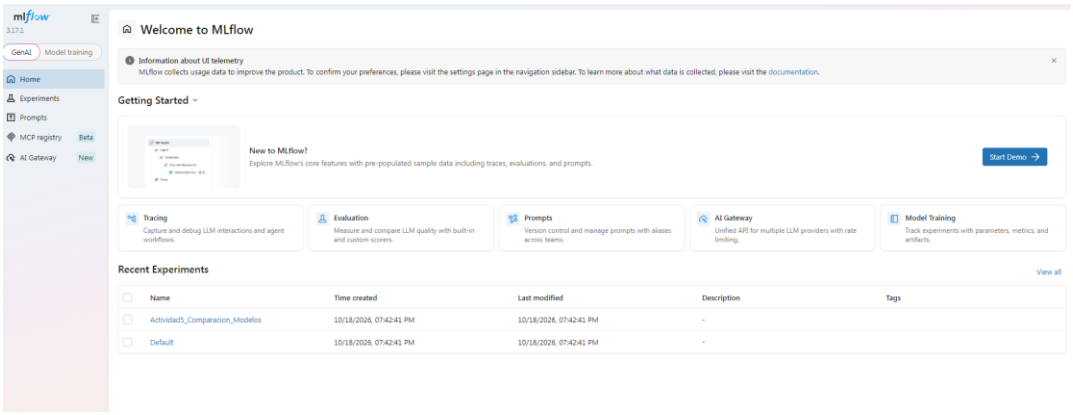
Limitaciones:

- Obtuvo valores inferiores en las principales métricas comparadas.

Seguimiento de experimentos con MLflow

Se utilizó MLflow para registrar y consultar los experimentos realizados durante el entrenamiento.

El experimento principal se denominó Actividad5_Comparacion_Modelos. Se verificaron corridas finalizadas para los algoritmos de regresión logística y Random Forest, con sus respectivas métricas.

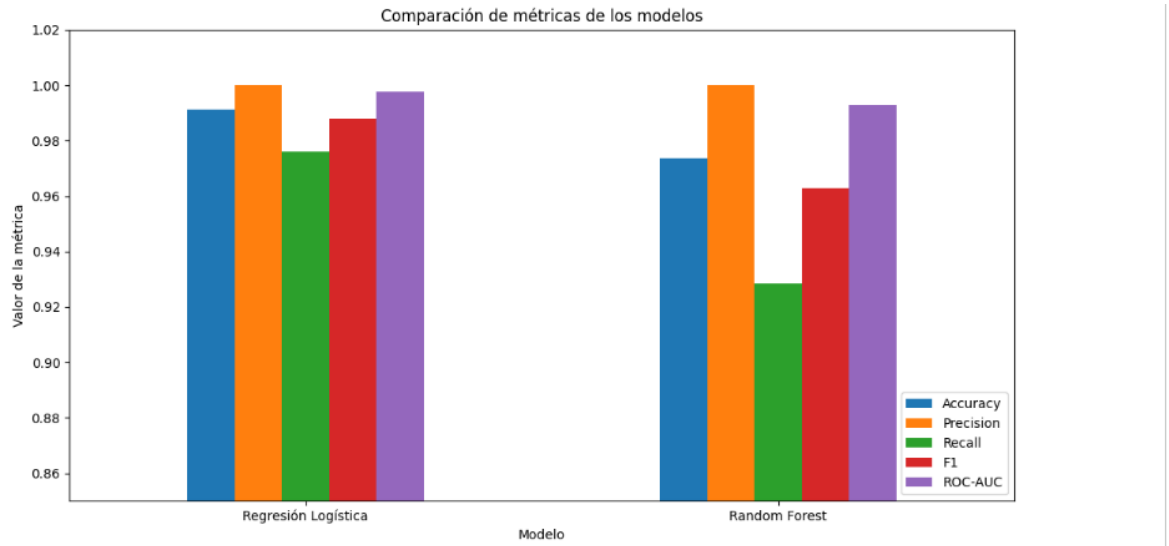


La inspección programática permitió comprobar que los resultados estaban almacenados, incluso cuando la interfaz web presentó un mensaje de error al consultar las corridas.

Entre las evidencias generadas se encuentran:

- Matriz de confusión de regresión logística.
- Curva ROC de regresión logística.
- Matriz de confusión de Random Forest.
- Curva ROC de Random Forest.
- Gráficas exploratorias de distribución y correlaciones.
- Archivo CSV con la comparación de métricas.

Estas evidencias permiten documentar el proceso y facilitar la revisión de los resultados.




```
Gráfica comparativa guardada en: /content/Actividad5/evidencias/graficas

Archivos existentes en la carpeta:
['Actividad5_distribuciones.png', 'Actividad5_correlaciones.png', 'comparacion_modelos.csv', 'Regresion_Logistica_roc.png', 'Regresion_Logistica_confusion.png',
```

FUENTES CONSULTADAS

- OpenIA (2025). *ChatGPT (versión GPT-4º)*
    - *https://chat.openai.com/*